

Kelompok 4 – Projek Praktikum Kecerdasan Buatan

Analisis Sentimen Ulasan Pelanggan E-Commerce Menggunakan Machine Learning dengan Implementasi Web Application

Anggota Kelompok :

1. Rivaldo Nainggolan (ketua) - 241712043
2. Annisa Jayanti Ad'nin - 241712033
3. William Tanu Wijaya - 2417120036

Pembuatan Kecerdasan Buatan untuk Analisa Review Ulasan Pembeli dengan teknik Sentiment Analysis. Berdasarkan data set review tokped/shopee.

Teknik Sentiment Analysis adalah teknik dalam AI / Machine Learning untuk menentukan emosi atau opini dari sebuah teks.

- Input = ulasan pembeli
- Output = label sentimen

Contoh :

"Barang bagus banget, pengiriman cepat" dilabeli Positif

"Barang rusak, kecewa banget" Negatif

Output utama yang akan dihasilkan :

1. Pengelompokan/klasifikasi sentimen, Positif 😊, Negatif 😞, Netral 😐
2. Score / Confidence(kepercayaan diri) user dalam menekankan ulasanya
Contoh : Positif (92%) Negatif (8%)
3. Insight, kata yang sering muncul di review positif atau negatif. Contohnya ..
Negatif: "rusak", "lama", "tidak sesuai"
Positif: "bagus", "murah", "cepat"
4. Visualisasi, Pie chart Sentiment atau Wordcloud.
 - a. Pie Chart Sentiment adalah grafik berbentuk lingkaran yang menunjukkan proporsi jumlah sentimen dalam dataset.
Misalnya hasil analisis:
 - a. Positif: 70%
 - b. Negatif: 20%
 - c. Netral: 10%pie chart akan membagi lingkaran sesuai persentase itu dan menunjukkan produk bagus atau ada masalah serius.
 - b. Wordcloud adalah visualisasi kata-kata yang sering muncul dalam teks. Semakin sering kata muncul maka semakin besar tampilannya. "bagus" ukuran besar, "murah" ukuran besar, "cepat" ukuran sedang. Bisa dipisah jadi wordcloud positif dan wordcloud negatif.

Data yang akan diambil dari review:

1. review_text yang berisi ulasan
2. rating penilaian bintang (1–5)
3. product_name

4. category
5. date
6. username

review_text	rating	product_name	category	date	username
barang bagus banget	5	Maskara	Make-Up	5/4/2026	Madun
jelek, rusak	1	Lipstik	Make-Up	31/3/2026	Udin
lumayan sih	3	Setrika	Elektronik	22/4/2026	Suptrani

Labeling (Supervised Learning) : Menggunakan auto labeling

- 4-5 ☆ Positif
 3 ☆ Netral
 1-2 ☆ Negatif

Alur Kerja

1. Mengambil dataset dari Kaggle
2. Coding dalam google lab atau jupyter notebook.
 Pembersihan data seperti hapus symbol, lowercase, hapus stopwords
 "Barang BAGUS!!!" jadi "barang bagus"
3. Labelling data yang udah bersih berdasarkan rating
4. Text Processing yang mengubah teks mentah (review user) menjadi bentuk yang bisa dipahami oleh komputer. Membersihkan data, Menyamakan format, Mengubah teks jadi fitur untuk model. Bisa tokenization atau stemming
 - a. Tokenization, proses memecah kalimat menjadi bagian kecil (kata/token)
 Contoh token "barang bagus banget" jadi ["barang", "bagus", "banget"]
 - b. Stemming, proses mengubah kata menjadi bentuk dasarnya

Kata Asli	Hasil stemming
Membeli	Beli
Berlari	Lari
Makanan	Makan
Bagusnya	bagus

5. Feature Extraction. proses mengubah teks menjadi angka agar bisa diproses oleh model Machine Learning. "barang bagus banget" jadi [0, 1, 0, 1, 1].
 Bisa pakai Bag of words atau TF-IDF :

- a. Bag Of Words, menghitung berapa kali setiap kata muncul.

1. barang bagus
2. barang jelek

Jadi ["barang", "bagus", "jelek"]

Kalimat	barang	bagus	jelek
Barang bagus	1	1	0
Barang jelek	1	0	1

- b. TF-IDF(lebih smart), Kata yang sering muncul di satu kalimat tapi jarang di seluruh dataset lebih penting.

TF (Term Frequency) seberapa sering kata muncul di satu dokumen.

IDF (Inverse Document Frequency) seberapa jarang kata itu di semua data

Contoh :

1. barang bagus banget

2. barang murah

Kata “barang” muncul disemua kalimat, dianggap tidak terlalu penting. ”bagus” muncul hanya di 1 kalimat, dianggap lebih penting.

TF-IDF akan kasih nilai kecil jika kata terlalu umum dan nilai besar jika kata penting

6. Modelling, proses melatih algoritma agar bisa mengenali pola dari data dan membuat prediksi. Misal input "barang bagus banget" Output Positif. Model akan belajar dari teks hasil TF-IDF dan label (positif / negatif). Bisa pakai model

- a. Naive Bayes (paling gampang cepat), menghitung probabilitas suatu kalimat termasuk ke kelas tertentu. Cara kerjanya misal ada kalimat "barang bagus" model akan cek

- seberapa sering kata "bagus" muncul di review positif
- seberapa sering muncul di negatif

Kata	Positif	Negatif
Bagus	50	2
Jelek	3	40

Maka ”bagus” kemungkinan besar positif, ”jelek” kemungkinan besar negatif

- b. Logistic Regression(sedikit lebih berat dari NB), menggunakan rumus matematika untuk menentukan probabilitas kelas. 0 negatif, 1 positif. Tapi sebenarnya 0.85 itu dibuat 85% positif.

Cara kerjanya, model mencari kombinasi kata yang paling mempengaruhi sentimen.

"bagus" +2 poin lalu ditotalkan +2 → positif

"jelek" -3 poin -3 → negative

- c. Support Vector Machine(akurasi tinggi dan perlu pemahaman kuat untuk menjelaskan), mencari garis pemisah terbaik antara data positif dan negative. Dengan tujuan Memaksimalkan jarak antar kelas

7. Evaluasi. cara mengukur seberapa baik model kalian dalam memprediksi data baru. Contohnya "barang jelek banget" model prediksi kalau itu Negatif, kenyataanya negatif berarti ☒. Hasil prediksi model akan dibandingkan dengan label asli.

- a. Confusion Matriks

	Prediksi Positif	Prediksi Negatif
Asli Positif	TP (True Positive)	FN (False Negative)
Asli Negatif	FP (False Positive)	TN (True Negative)

TP = benar positif

TN = benar negatif

FP = salah (dibilang positif padahal negatif)

FN = salah (dibilang negatif padahal positif)

Contoh :

Review: "bagus banget"

Asli: Positif

Prediksi: Negatif

→ FN ✗

- b. Accuracy = $(TP + TN) / \text{total data}$. Seberapa banyak prediksi yang benar.

Contoh : Dari 100 data, 80 benar. Akurasi 80%.

Kalau data tidak seimbang bisa menipu. Contoh = 90% data positif, model selalu jawab “positif” akurasi tetap lebih tinggi.

- c. Precision, $\text{Precision} = \text{TP} / (\text{TP} + \text{FP})$. Dari semua yang diprediksi positif, berapa yang benar-benar positif? Seberapa akurat prediksi positif?

Contoh : Model mengatakan 50 % review positif tapi hanya 40% positif yang benar. Maka precision $40/50\% = 80\%$

- d. Recall. Dari semua data positif asli, berapa yang berhasil ditemukan model? .

Contoh : ada 100 review positif asli, model hanya dapat 70%. Maka recall 70%

- e. F1-Score, $F1 = 2 \times (\text{Precision} \times \text{Recall}) / (\text{Precision} + \text{Recall})$. Gabungan antara precision dan recall. Untuk mencari keseimbangan, dikarenakan:

Precision tinggi tapi recall rendah - jelek

Recall tinggi tapi precision rendah - juga jelek

- 8. Deployment bisa website atau mobile apps, yang meminta input data berupa teks ulasan. Lalu outputnya sentiment.

- a. Input Teks. User bisa ketik review:

"barang rusak dan pengiriman lama"

- b. Output Sentimen, Langsung tampil:

Sentimen: Negatif 😞

- c. Confidence Score, Contoh:

- d. Negatif (92%)

- e. Bisa juga buat fitur fitur bagus lainnya (opsional)

